Panduan Pemula

Menggunakan AI di Komputer Sendiri

dengan LM Studio

Table of Contents

Apa itu AI, LLM, dan SLM?....3
AI (Artificial Intelligence / Kecerdasan Buatan)....3
LLM (Large Language Model)....3
SLM (Small Language Model)....4
Bisakah tanpa Internet?....4
AI tanpa internet (umum)....5
SLM tanpa internet (paling ideal)....5
LLM tanpa internet (bisa tapi ada syarat)....6
Aplikasi untuk Menjalankan LLM dan SLM....6
LM Studio sebagai Solusi....7
Mengunduh LM Studio....7
Di Ubuntu 24.04....7
Di Windows 11....7
Menjalankan LM Studio....7
Konfigurasi Awal LM Studio....8
Mengunduh Model untuk LM Studio....11
Pesan Pertama di LM Studio....11
Manajemen Chat di LM Studio....12
Fitur LM Studio Lainnya....13
Penutup....14

Apa itu AI, LLM, dan SLM?

AI (Artificial Intelligence / Kecerdasan Buatan)

AI adalah istilah payung untuk semua sistem komputer yang dibuat agar bisa meniru kemampuan kecerdasan manusia.

Contoh kemampuan AI:

- Mengenali wajah
- Bermain catur
- Mengemudi mobil
- Menerjemahkan bahasa
- Membuat gambar / teks

Jenis AI sangat luas:

- Rule-based AI (pakai aturan IF–THEN)
- Machine Learning
- Deep Learning
- LLM, SLM, Computer Vision, Speech Recognition, dll

LLM dan SLM adalah bagian dari AI, bukan sesuatu yang terpisah.

LLM (Large Language Model)

LLM adalah model AI khusus bahasa dengan ukuran sangat besar (banyak parameter), dilatih dari data teks dalam jumlah masif.

Ciri utama:

- Fokus pada bahasa manusia
- Parameter bisa miliaran
- Butuh GPU besar dan VRAM tinggi
- Sangat fleksibel & pintar secara umum

Contoh LLM:

- GPT-4 / GPT-4o
- LLaMA 2 / 3 (versi besar)
- Claude
- Gemini

Kemampuan:

- Menjawab pertanyaan kompleks
- Menulis kode
- Menjelaskan konsep

- Chat multi-topik
- Reasoning lintas domain

Kekurangan:

- Berat
- Mahal
- Tidak efisien untuk perangkat kecil

SLM (Small Language Model)

SLM adalah versi lebih kecil dan ringan dari language model.

Ciri utama:

- Parameter jauh lebih sedikit

Bisa jalan di:

- Laptop
- CPU
- Edge device

Lebih hemat daya & biaya

Biasanya spesifik tugas

Contoh SLM:

- Phi (Microsoft)
- Gemma small
- LLaMA small variants
- Model 1–7B parameter

Kemampuan:

- Chat sederhana
- Ringkasan teks
- Klasifikasi
- Asisten lokal (offline)

Kekurangan:

- Kurang pintar untuk topik kompleks
- Konteks terbatas
- Reasoning lebih lemah dibanding LLM besar

Bisakah tanpa Internet?

AI, SLM, dan LLM bisa berjalan tanpa internet, tergantung cara dan tempat menjalankannya. Berikut penjelasan yang praktis dan realistis.

AI tanpa internet (umum)

Sebagian besar AI tidak butuh internet saat inferensi.

Contoh AI offline:

- Face recognition di kamera
- OCR (Tesseract)
- Speech-to-text lokal
- AI di mobil (ADAS)
- Image classification lokal

Internet hanya diperlukan saat:

- Training
- Update model
- Akses API cloud

SLM tanpa internet

SLM adalah kandidat terbaik untuk offline.

Ciri:

- Ukuran kecil
- Bisa jalan di CPU
- Cocok untuk laptop / PC spek rendah
- Konsumsi RAM rendah

Contoh:

- Phi-2 / Phi-3 (versi kecil)
- Gemma 2B
- LLaMA 3 8B (masih tergolong “kecil”)

Tools offline populer:

- Ollama
- LM Studio
- llama.cpp
- koboldcpp

Setelah model diunduh, tidak perlu internet sama sekali.

LLM tanpa internet

LLM bisa offline, bukan mitos, tapi:

Syarat utama:

- Model sudah di-download
- Storage besar
- RAM besar
- Idealnya GPU dan VRAM

Contoh kebutuhan RAM (CPU / hybrid inference):

- LLM 7B → ±8–16 GB RAM (quantized)
- LLM 13B → ±16–32 GB RAM
- LLM 70B → ≥128 GB RAM atau GPU dengan ≥48 GB VRAM

Tanpa GPU:

- Bisa pakai quantization (Q4, Q5, Q8)
- Lebih lambat, tapi tetap jalan

Aplikasi untuk Menjalankan LLM dan SLM

LLM dan SLM dijalankan oleh semacam tools yang dapat membaca data dari LLM dan SLM tersebut kemudian mengolahnya sebagai respons dari prompt.

Beberapa contoh tools semacam itu adalah:

- Ollama
- llama.cpp

Tools tersebut biasanya dipermudah penggunaannya dengan frontend tertentu:

- Open WebUI
- AnythingLLM

Atau dengan aplikasi favorit saya:

- LM Studio

Di samping itu, kita juga bebas untuk memilih yang manapun karena tools tersebut bisa didapatkan secara gratis.

LM Studio sebagai Solusi

Karena LM Studio merupakan aplikasi siap pakai dan user interfacenya menurut saya cukup mudah dipahami, maka saya membahas LM Studio sebagai solusi untuk AI lokal.

Mengunduh LM Studio

Untuk mengunduh dan menyiapkan LM Studio, ikuti langkahnya sesuai dengan sistem operasi yang Anda gunakan.

Saya hanya membahas untuk Ubuntu 24.04 dan Windows 11.

Jika sistem operasi Anda hanya beda sedikit versi, mungkin caranya tidak terlalu berbeda.

Di Ubuntu 24.04

Buka https://lmstudio.ai/download dan pilih Linux x86. Ambil yang nomor versinya yang paling besar.

Selanjutnya, klik tombol download.

Di Windows 11

Buka https://lmstudio.ai/download dan pilih Windows x86. Ambil yang nomor versinya yang paling besar.

Selanjutnya, klik tombol download.

Mulai dari sini, pembahasan topik tulisan ini hanya pada Ubuntu 24.04

Menjalankan LM Studio

Binary untuk Linux yang telah kita download tadi merupakan aplikasi AppImage, dan itu berarti aplikasinya portable.

Karena portabel, tidak perlu diinstall.

Anda tinggal memberi izin untuk execute file AppImage tersebut kemudian menjalankannya.

Jika saat ini Anda berada di dalam directory di mana file AppImage berada, maka Anda hanya perlu lakukan ini:

```
chmod +x ./LM-Studio-versi-arsitektur.AppImage
```

Misalnya:

```
chmod +x ./LM-Studio-0.3.33-1-x64.AppImage
```

Setelah itu, jalankan aplikasi tersebut.

Tampilan awalnya seperti ini:

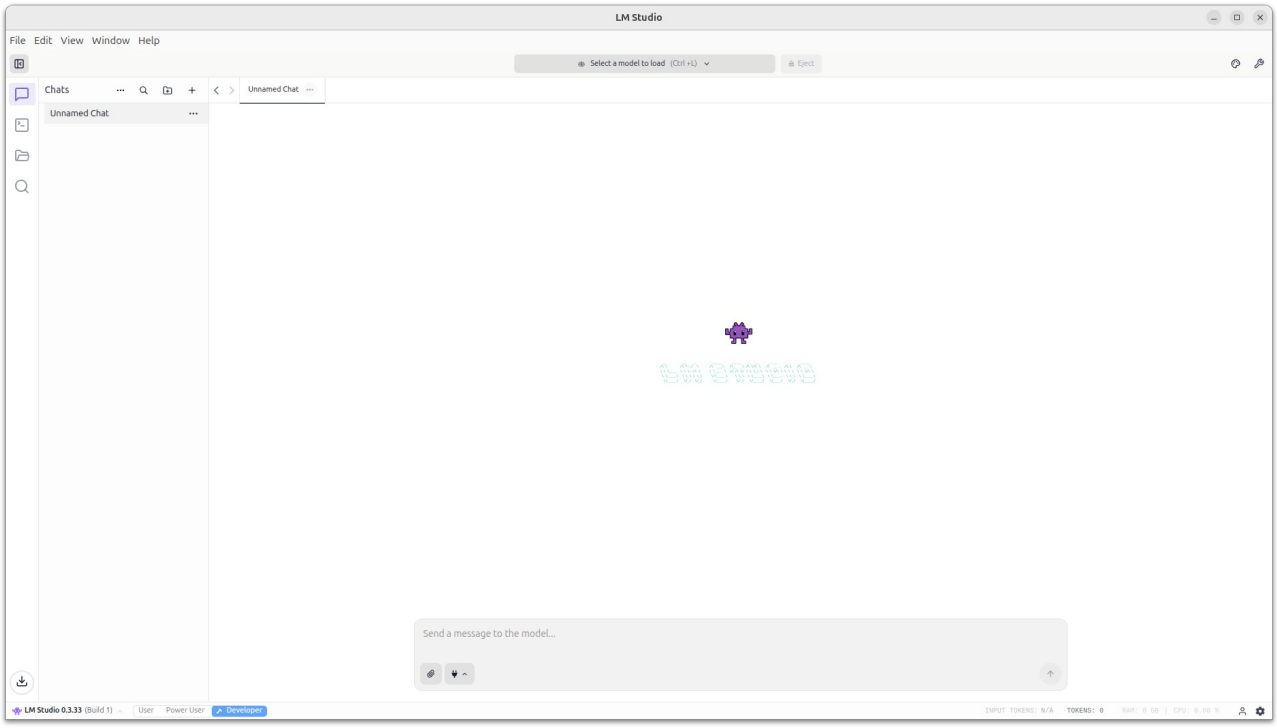

Konfigurasi Awal LM Studio

Sebelum kita lanjut ke konfigurasi awal, pastikan Anda menggunakan developer mode dari LM Studio.

Caranya dengan mengklik tombol "Developer" di sisi kiri bawah aplikasi LM Studio.

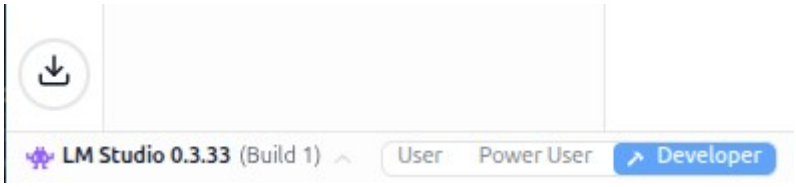

Selanjutnya, klik tombol bergambar gerigi di bagian kanan bawah aplikasi.

Nanti, akan muncul jendela konfigurasi. Tampilannya seperti ini:

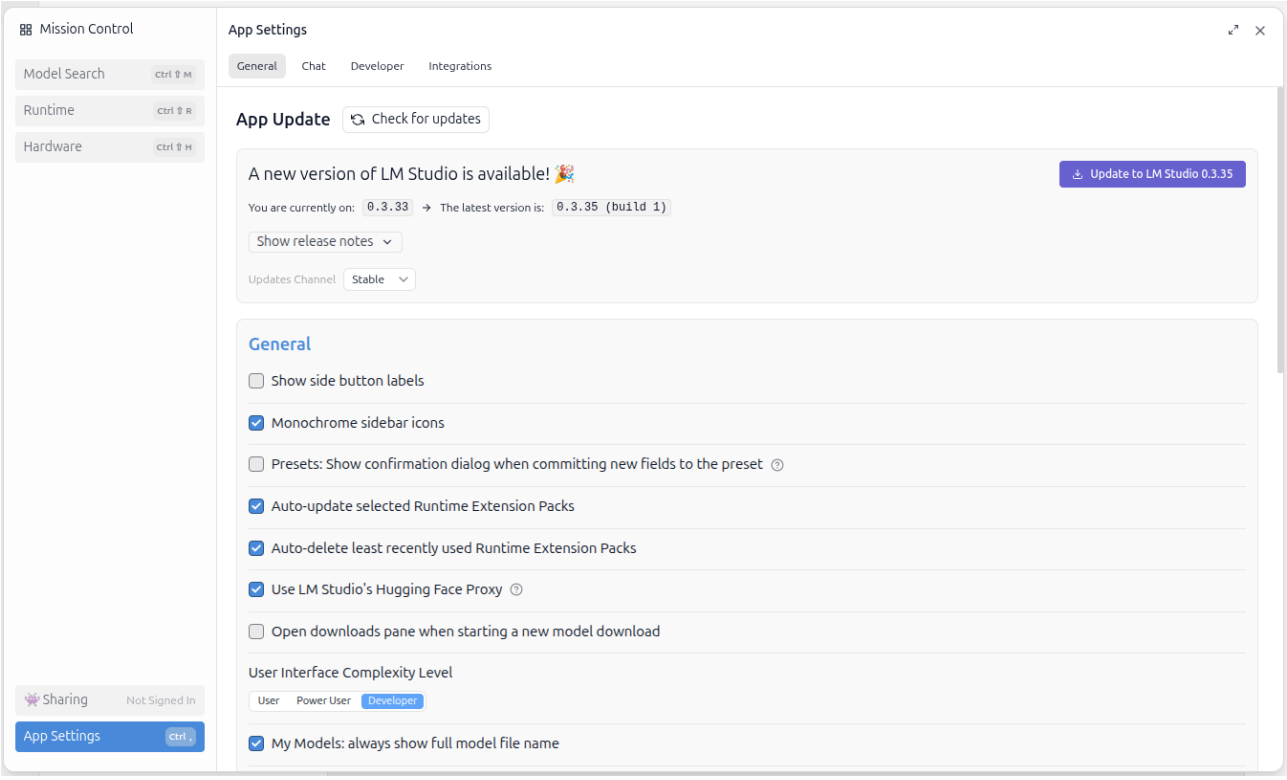

Ada 5 bagian utama di sana:

- Model Search
- Runtime
- Hardware
- Sharing
- App Settings

Tapi hanya 4 saja yang perlu Anda perhatikan:

- Model Search: Untuk download LLM.
- Runtime: Untuk konfigurasi runtime.
- Hardware: Untuk konfigurasi hardware.
- App Settings: Konfigurasi sisanya.

Model LLM di-host di URL tertentu yang biasanya ada di Hugging Face.

Karena itulah, fitur Model Search bisa untuk mencari sekaligus mengunduh model LLM dari sana.

Runtime adalah tempat kita memilih engine apa yang akan digunakan di LM Studio, apakah CPU, Vulkan, atau CUDA.

CUDA hanya bisa digunakan jika Anda pakai GPU NVidia seri tertentu.

Jika Anda hanya gunakan komputer tanpa dedicated GPU seperti yang saya gunakan (Mini PC MSI Cubi 5 12 M), gunakan Runtime yang CPU.

Caranya dengan memilih CPU pada dropdown di tab "Runtime" ini:

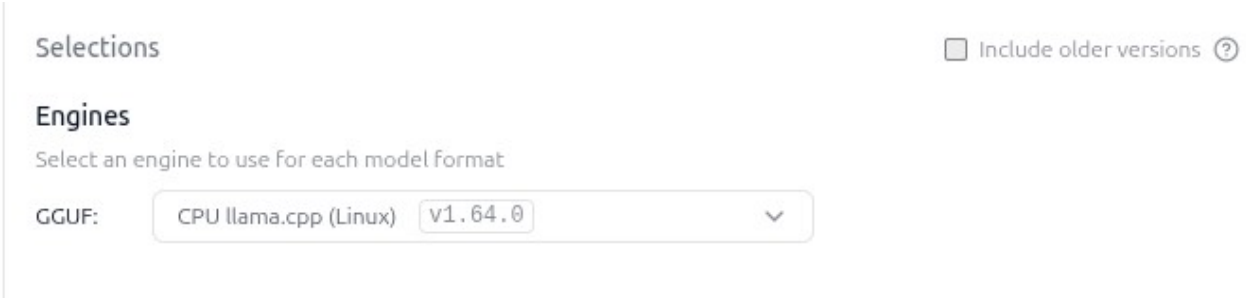

Di tab "Hardware", pilih "Relaxed" untuk setting "Guardrails".

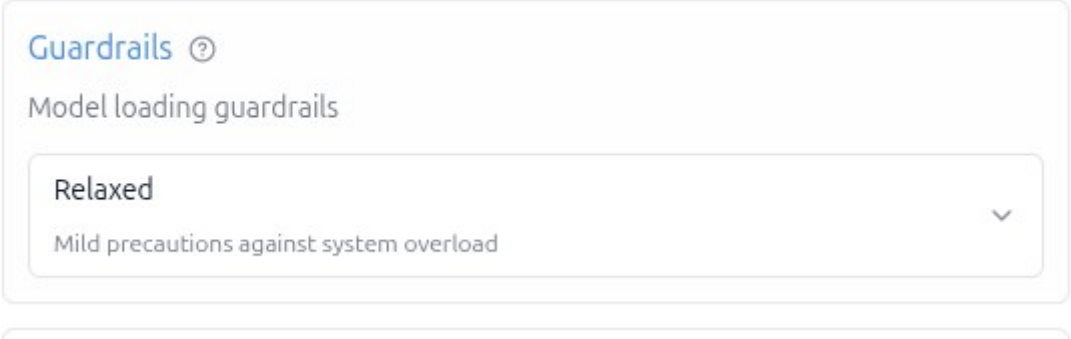

Selain itu, nonaktifkan "Offload KV Cache to GPU Memory".

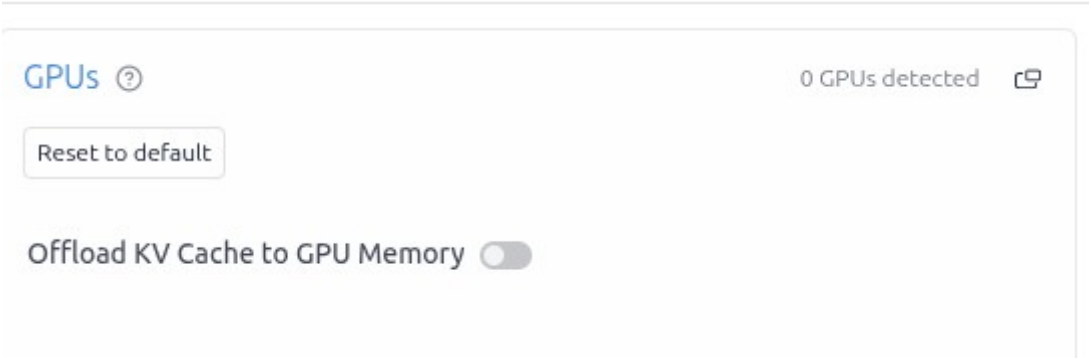

Sekarang, biarkan konfigurasi dari tab "App Settings" sebagai mana adanya. Jangan diubah.

Mengunduh Model untuk LM Studio

Aplikasi LM Studio sudah bisa dijalankan, konfigurasi awal sudah dilakukan.

Sekarang, tinggal satu langkah lagi sebelum chat dengan AI dimulai di komputer lokal Anda.

Satu langkah yang cukup menentukan: Mengunduh model LLM.

Jika Anda menggunakan mini PC tanpa dedicated GPU seperti saya, kita tidak bisa terlalu menginginkan kesempurnaan.

Itu karena biasanya model yang besar membutuhkan GPU yang kuat dengan VRAM yang cukup besar.

Sedangkan kita hanya pakai mini PC tanpa dedicated GPU.

Maka pilihan kita adalah menggunakan model dengan parameter yang tidak terlalu banyak.

Saya sarankan Anda gunakan gemma3 karena pada versi kecilnya, jawabannya termasuk cukup akurat.

Sekarang, kita akan download model tersebut.

Bukalah konfigurasi LM Studio, kemudian klik Model Search.

Nanti di kotak pencariannya, ketikkan "gemma3 1b".

Pilih sesuai gambar, jika masih ada:

Selanjutnya, klik tombol "Download" di kanan bawah jendela "Model Search".

Jika model tersebut tidak tersedia, silakan cari gemma3 1b versi lain.

Pesan Pertama di LM Studio

Untuk memulai chat dengan gemma3 1b di LM Studio, Anda harus memuat modelnya dulu ke memori.

Caranya adalah dengan mengklik tombol "Select a Model to Load" di bagian tengah atas aplikasi.

Setelah diklik, daftar model yang telah Anda download akan muncul. Pilihlah gemma3 1b Anda di situ.

Setelah terpilih, maka model akan dimuat dan memakan cukup waktu. Tunggulah sejenak.

Setelah model selesai dimuat, klik "Create a New Chat", lalu ketikkan prompt Anda, misalnya:

```
Hai, bisakah Anda perkenalkan diri Anda?
```

Berikut ini ilustrasinya:

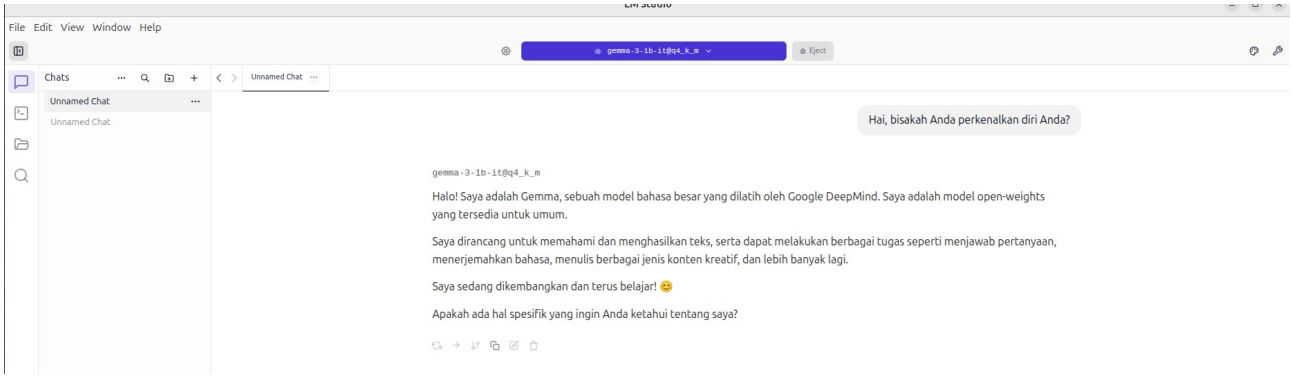

Manajemen Chat di LM Studio

Sementara Anda sibuk mengobrol dengan gemma3, Anda akan mendapati satu tab chat lama kelamaan akan panjang.

Jika diteruskan maka akan repot scrolling-nya.

Anda bisa membuat tab chat baru dengan mengklik tombol "+" di kiri atas sidebar aplikasi.

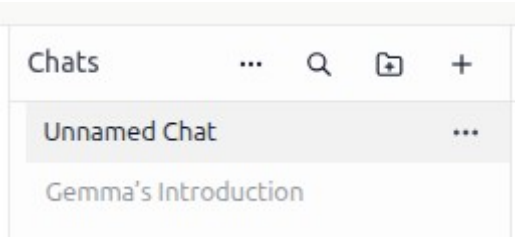

Anda juga bisa menghapus chat dengan mengklik tombol "..." di bagian kanan atas dari tab chat yang ada di dalam sidebar kiri aplikasi.

Jika tab chat Anda sudah cukup banyak dan Anda ingin melakukan pencarian, ada tombol kaca pembesar di kiri atas sidebar aplikasi.

Fitur LM Studio Lainnya

Asalkan Anda tidak lupa memilih "Developer Mode" dari LM Studio seperti yang kita lakukan di awal tulisan ini, sebenarnya ada fitur yang sangat berguna, yang bisa Anda akses di LM Studio.

Fitur itu adalah semacam fitur REST API Server.

Dengan menjalankan fitur tersebut, Anda bisa mengubah aplikasi LM Studio menjadi backend untuk LLM.

Berikut ini tampilannya:

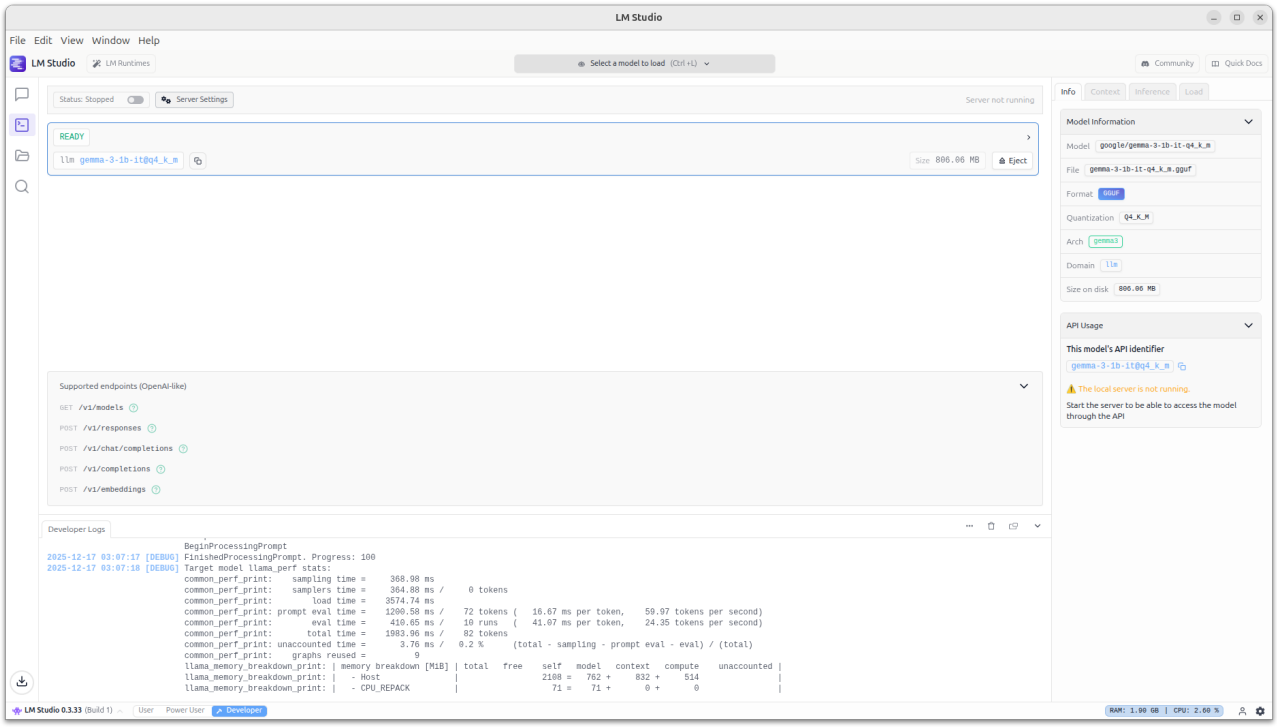

Sekarang, pastikan model LLM yang telah Anda muat tadi belum dilepas/di-eject.

Kemudian, jalankan server tersebut dengan mengubah toggle server status ini menjadi "Running":

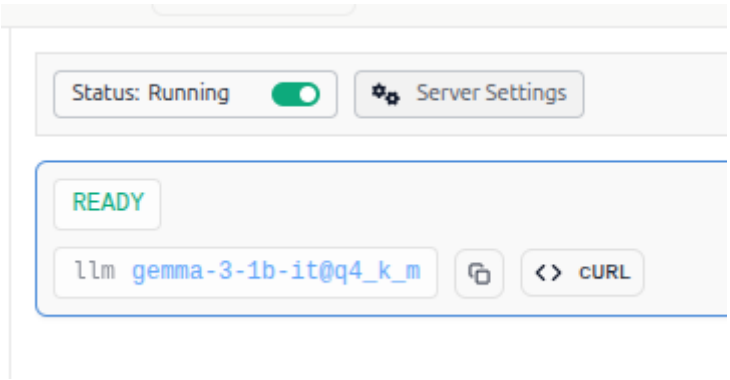

Selanjutnya, buka browser Anda dan isi dengan URL ini:

```
http://localhost:1234/v1/models
```

Nanti akan muncul daftar model yang telah Anda download dari "Model Search" dan mungkin yang dicopy secara manual ke folder model LM Studio Anda.

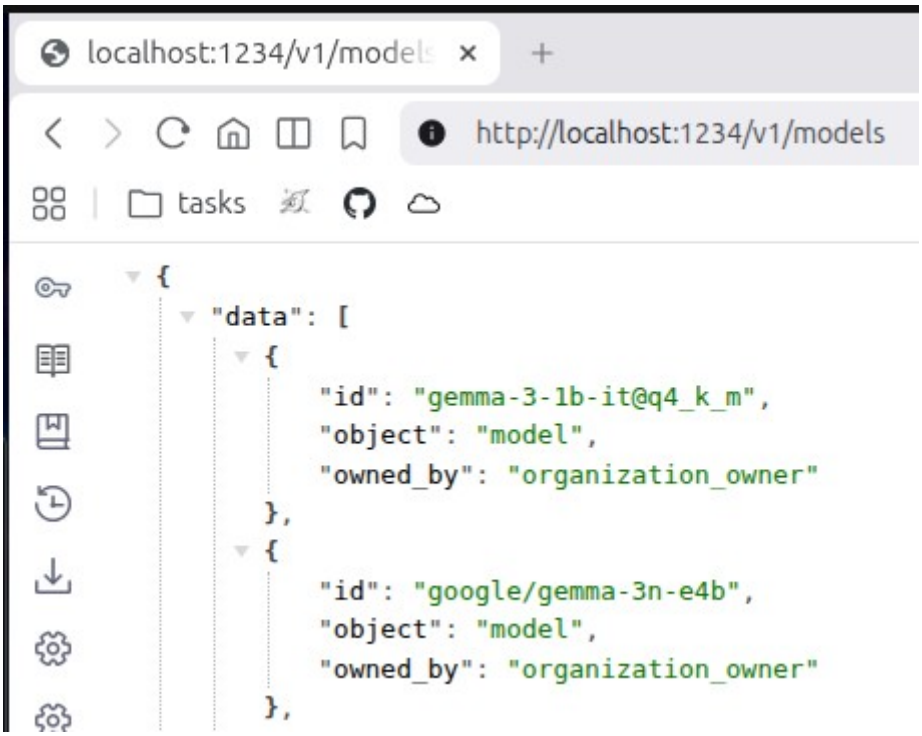

Itu baru contoh 1 endpoint. Anda bisa menggunakan endpoint yang lain jika Anda tahu caranya.

Penutup

Telah kita saksikan bahwa di mini PC sekalipun, kita bisa menggunakan AI walaupun model yang digunakan memang tidak besar.

Walaupun demikian itu masih lebih baik karena walaupun model yang digunakan kecil, asalkan kita tahu cara memanfaatkannya, kemungkinan ada gunanya.